NVIDIA PhysicsNeMo 교육 내용 통합 정리

2026년 11월 9일 | 1부·2부 보정 녹취록 기반 | MyDesk PhysicsNeMo 블로그 / Codex 업로드용

문서 성격: 교육 녹취 기반의 상세 요약입니다. 음성 원본과 대조하지 않은 오인식 가능 구간은 확정적인 수치나 사실로 단정하지 않았습니다. 실습값은 일반적인 설계·학습 허용기준이 아닙니다.

1. 교육 목적 및 전체 흐름

교육의 목표는 CAE Simulation 결과를 AI 학습 데이터로 변환하고 NVIDIA PhysicsNeMo 기반 대리모델(Surrogate Model)을 학습하여, 새로운 설계조건에 대한 변위·응력 등의 결과를 예측하고 Omniverse에서 시각화하는 전체 절차를 이해하는 것입니다.

CAE Simulation 수행 → DOE/LHS 설계점 생성 → RST 결과 확보 → PyAnsys DPF로 VTU 변환 → 학습 데이터 전처리 → PhysicsNeMo 모델 학습 → 새로운 조건 추론 → API 및 Omniverse 시각화

구분	기존 CAE Simulation	AI 대리모델
원리	지배방정식과 수치해법	데이터 기반 입력·출력 관계 학습
비용	새 조건마다 수치 계산	학습 이후 상대적으로 빠른 추론 가능
한계	계산시간·모델링·수치오차	학습 범위·데이터 품질·일반화 성능

2. AI 기반 디지털 트윈 및 Omniverse 시연

1부에서는 블레이드 또는 구조 부품, 지그, 와이어, 입력 슬라이더 등이 포함된 3D 장면에서 사용자가 하중을 변경하면 학습된 AI 모델이 변형 및 von Mises 응력 결과를 예측하고 화면을 갱신하는 시연을 소개했습니다. OpenUSD 기반 Omniverse 장면과 추론 시스템은 API로 연결됩니다.

- 시연은 매번 CAE Solver를 다시 실행하는 대신 학습된 모델을 호출하는 구조입니다.
- 응답속도에는 GPU 추론 외에도 API 통신, 데이터 처리, 화면 갱신시간이 영향을 줍니다.
- 녹취에 약 2.9%, 3.7% 등의 오차 수치가 등장하지만 평가 항목과 계산식은 불명확하여 일반 정확도 기준으로 사용할 수 없습니다.
- 시각화 장면의 모든 부품이 AI 예측 대상이라는 뜻은 아니며 일부는 표시용 구성요소일 수 있습니다.

3. 실습 환경과 사용 도구

도구	용도
Ansys Workbench	설계변수별 정적 구조 Simulation
Python / Jupyter Notebook	데이터 처리·셀 실행·결과 확인
PyTorch / PhysicsNeMo	GPU 기반 신경망 학습·추론
PyAnsys DPF	RST의 Mesh·결과 추출
VTU / VTK	비정형 격자와 물리량 저장
NumPy	배열 및 수치 처리
Omniverse / OpenUSD	3D 장면과 결과 시각화
HTTP API	추론 시스템과 시각화 프로그램 연결

실습에서는 Python 버전, 가상환경, 라이브러리와 GPU 관련 패키지의 호환성, Jupyter 커널 선택 및 셀 실행 순서를 확인했습니다. Omniverse의 카메라 뷰는 Python으로 설정하는 방법도 소개했습니다.

4. DOE와 Latin Hypercube Sampling(LHS)

2부에서는 상단부를 구속한 후크 형태의 정적 구조 모델을 대상으로 두께와 하중을 설계변수로 설정했습니다. 교육 예제의 범위는 두께 6~12 mm, 하중 100~500 N이며 LHS를 사용해 10개 설계점(DP0~DP9)을 선택했습니다.

DOE(실험계획법)는 어떤 조건을 계산할지 체계적으로 계획하는 방법이며, LHS는 각 변수 범위를 구간으로 나누어 설계공간에 표본을 분산시키는 방법입니다. 케이스당 계산시간이 긴 CFD 등에서는 설계점 선택 자체가 비용과 정확도에 큰 영향을 줍니다.

- Python으로 생성한 설계점의 케이스 ID, 두께, 하중을 CSV로 저장합니다.
- Workbench Parameter Set에 설계점별 값을 입력하고 반복 Simulation을 수행합니다.
- 최대 응력·변위 같은 요약값뿐 아니라 각 Design Point의 원본 RST 결과를 보존해야 전체 필드 학습이 가능합니다.
- Workbench 결과 파일 보존 설정과 case_001~case_010 같은 일관된 파일명이 중요합니다.
- 10개 설계점은 실습용이며 실제 학습에서 충분한 데이터 수를 의미하지 않습니다.

5. RST → VTU 변환과 데이터 정합성

Ansys RST는 원본 Simulation 결과 파일이고, VTU는 비정형 격자, 노드·요소 연결성, 물리량을 저장할 수 있는 VTK 계열 형식입니다. PyAnsys DPF로 RST를 읽어 AI 학습에 필요한 데이터를 추출합니다.

추출 정보	의미
Node ID / Coordinates	노드 식별과 X,Y,Z 위치
Element ID / Connectivity	요소 식별 및 노드 연결 관계
Displacement	Ux, Uy, Uz 및 변위 크기

추출 정보	의미
Stress Tensor	정규응력·전단응력 성분
von Mises Stress	등가응력
Case ID / 설계변수 / 단위	학습 입력과 정답의 대응 관계

녹취에는 한 예제에서 노드 약 13,668개, 요소 약 8,024개가 언급되지만 다른 배열 크기도 혼재하므로 정확한 값은 원본 실습 파일 확인이 필요합니다. Node ID와 배열 순서는 동일하다고 가정할 수 없으므로 노드 ID를 기준으로 좌표와 결과를 정렬해야 합니다.

von Mises 응력은 응력 텐서의 비선형 함수입니다. 먼저 응력 성분을 평균한 후 von Mises를 계산하는 방식과, 먼저 von Mises를 계산한 후 평균하는 방식은 일반적으로 동일하지 않습니다. 요소→노드 외삽 및 평균 처리 방식은 학습 정답을 바꿀 수 있습니다.

교육 예제의 단위 변환: 좌표·변위 m→mm는 ×1,000, 응력 Pa→MPa는 ÷1,000,000입니다. 이 단위 변환은 뒤에서 설명하는 통계적 정규화와 다른 절차입니다. VTU 변환 후에는 최대값뿐 아니라 노드 대응, 좌표, 연결성, 단위 및 전체 필드도 검증해야 합니다.

6. Train / Validation / Test 분할과 데이터 누출

분할	목적	10개 실습	100개 예시
Training	가중치 학습	6	80
Validation	학습 중 성능·모델 선택	2	10
Test	학습 후 최종 평가	2	10

교육에서는 난수 시드 42를 사용해 재현 가능한 분할을 설명했습니다. Training, Validation, Test의 비율은 예시일 뿐 고정된 공식 기준은 아닙니다.

데이터 누출(Data Leakage)을 막기 위해 먼저 케이스를 분할하고 Training 데이터만으로 정규화 평균·표준편차를 계산해야 합니다. Validation, Test 및 실제 추론 데이터에는 Training에서 계산한 동일한 통계값을 적용합니다.

설계공간에서는 Training 점의 분포와 Convex Hull(볼록껍질)을 소개했습니다. 학습 범위 밖 외삽(Extrapolation)에서는 오차가 커질 수 있으며, Convex Hull 내부라고 해도 정확도가 자동으로 보장되지는 않습니다.

7. Z-score 정규화와 역정규화

응력과 변위 등 물리량은 값의 규모가 달라 학습 손실에 불균형을 일으킬 수 있습니다. 교육에서는 Z-score 표준화를 사용했습니다: $z = (x - \mu) / \sigma$. μ와 σ는 Training 데이터에서 계산한 평균과 표준편차입니다.

추론 후 물리량 복원은 $x = z\sigma + \mu$를 사용합니다. 표준편차가 0인 변수는 별도 처리가 필요하며, 정규화→역정규화 결과가 원본과 일치하는지 점검해야 합니다.

변위는 Ux, Uy, Uz 성분을 예측한 뒤 크기 $|U| = \sqrt{(Ux^2+Uy^2+Uz^2)}$를 계산할 수도 있고, 크기 자체를 학습할 수도 있습니다. 응력도 각 성분을 학습할지 von Mises를 직접 학습할지 선택에 따라 정답 정의와 성능이 달라집니다.

8. 노드 샘플링과 미니배치

한 케이스에 약 10,000~14,000개 노드가 있는 예제에서 GPU VRAM 부담을 줄이기 위해 케이스당 4,096개 노드를 선택하고, 배치당 2개 케이스를 묶어 총 8,192개 노드를 처리하는 방식을 설명했습니다. 4,096은 실습용 임의 설정이며 최적·권장 기준이 아닙니다.

- 두께 변화로 Mesh가 달라지면 케이스별 노드 수와 요소 수가 달라질 수 있습니다.
- 모든 노드를 단순 결합하면 노드 수가 많은 케이스의 손실 기여도가 커질 수 있습니다.
- 케이스별 가중치·평균 처리와 노드 샘플링 방식을 학습 목적에 맞게 정해야 합니다.
- Training에서는 Shuffle 및 샘플 변경을 활용할 수 있지만 Validation/Test에서는 평가 재현성을 우선합니다.
- 무작위 샘플링으로 응력 집중부 등 중요한 영역이 누락되지 않는지 확인해야 합니다.

9. PhysicsNeMo 학습의 기본 원리

PhysicsNeMo는 PyTorch 기반의 물리·공학 AI 모델 개발을 지원합니다. 학습 과정은 입력 데이터 → 순전파(Forward) → 예측값과 CAE 정답 비교 → 손실함수 계산 → 역전파(Backpropagation) → Optimizer 가중치 갱신의 반복입니다.

용어	정의
Batch	한 번에 모델에 공급하는 데이터 묶음
Step	배치 하나에 대한 학습·가중치 갱신
Epoch	Training 데이터 전체를 한 번 처리하는 주기
Loss	예측과 정답의 차이를 측정하는 목적함수
Overfitting	Training에 지나치게 맞춰져 새로운 조건의 성능이 낮아지는 현상

교육에서는 발열량과 공간 좌표를 입력하여 정상상태 온도 분포를 예측하는 열 문제로 학습 개념을 설명했습니다. Training Loss 감소만으로 일반화 성능을 판단하지 않고 Validation 및 Test 결과를 함께 확인해야 합니다.

10. GNN(Graph Neural Network)

GNN은 노드(Node)와 연결선(Edge)으로 구성된 그래프의 관계를 학습합니다. CAE Mesh의 연결 관계와 개념적으로 연관됩니다. Message Passing을 통해 이웃 노드의 특징을 수집·갱신하며, 여러 단계를 반복하면 더 먼 노드의 영향도 반영할 수 있습니다.

교육에서 소개한 구성은 Encoder(입력 특징 변환) → Processor(노드·Edge 정보 전달) → Decoder(온도 등 물리량 출력)입니다. 녹취에는 내부 특징 약 32개, 메시지 전달 6단계가 언급되지만 실습 설정값이지 일반 기준은 아닙니다.

GNN 열 문제 실습에서는 학습 전후의 온도 분포, Loss 변화 및 시험 케이스의 오차를 비교했습니다.

11. FNO(Fourier Neural Operator)

FNO는 입력 함수와 출력 함수 사이의 관계를 Fourier 공간에서 학습하는 Neural Operator 계열 모델입니다.
교육에서는 공간적으로 완만한 변화와 급격한 변화에 대응하는 주파수 성분을 설명하고, 입력 특징 변환→Fourier 연산→출력 변환의 구조를 소개했습니다.

동일한 정상상태 열 문제에 GNN과 FNO를 적용하여 학습 전후의 온도 분포, Loss 및 시험 오차를 비교했습니다. 해당 실습에서 한 모델이 더 좋은 결과를 보였더라도 모든 문제에서 우수하다는 결론은 아닙니다.

12. Transformer 계열 모델

후반부에는 Transformer 기반 모델과 대규모 격자·데이터 처리에 따른 계산량 및 메모리 문제를 소개했습니다. 녹취에 Transolver 계열로 추정되는 명칭이 있으나 정확한 모델명·버전·구조는 불명확하여 확정하지 않았습니다.

모델	핵심 접근	교육에서의 비중
GNN	그래프의 이웃 노드 관계·Message Passing	열 문제 실습
FNO	Fourier 공간에서 함수 간 관계 학습	동일 열 문제 비교
Transformer 계열	Attention 기반 관계 학습 등	개념 및 대형 격자 처리 소개

13. 추론·API·Omniverse 연동

학습된 모델은 새로운 입력조건을 받아 변위·응력 등 학습한 물리량을 추론합니다. 학습 시 사용한 입력 형식과 정규화 기준을 유지하고, 출력값은 역정규화하여 실제 단위로 복원해야 합니다.

사용자 입력(하중·두께 등) → API 요청 → PhysicsNeMo 모델 추론 → 결과 가공·역정규화 → API 응답 → Omniverse 변형 형상·Contour 갱신의 흐름입니다. OpenUSD는 3D 장면을 구성하며, 카메라 뷰 등 일부 동작은 Python으로 제어합니다.

14. 전체 파이프라인 검증 체크리스트

- CAE 모델의 물성·경계조건·Mesh·결과 자체가 타당한지 확인합니다.
- DOE 설계점의 범위와 분포가 목표 설계공간을 포괄하는지 검토합니다.
- RST 원본 파일과 케이스별 입력조건의 대응 관계를 보존합니다.
- VTU 변환 시 Node ID, 연결성, 좌표, 단위 및 물리량을 대조합니다.
- von Mises 계산 순서, 요소→노드 평균·외삽 방식이 일관적인지 확인합니다.
- Train/Validation/Test 분할 이후 Training만으로 정규화 통계값을 계산합니다.
- 노드 샘플링이 국부 응력 집중을 누락하거나 케이스별 편향을 만들지 않는지 검토합니다.
- Loss뿐 아니라 Validation/Test의 물리량 오차와 공간 분포를 비교합니다.
- 추론 시 학습 범위를 벗어난 외삽 조건을 별도 관리합니다.
- Omniverse 표시값과 실제 예측 물리량의 단위·좌표계·변형 배율을 확인합니다.

15. 구조 Simulation 업무 적용에 대한 기술적 해석

교육의 Ansys RST 파이프라인은 특정 Solver의 전용 학습 원리가 아닙니다. Abaqus ODB에서도 좌표, 요소 연결성, 변위, 응력, 설계조건 등을 추출하여 유사한 데이터 구조를 만들 수 있습니다. 단, ODB 전용 추출 코드가 필요하며 Integration Point, Nodal Extrapolation, Averaging 등 결과 위치와 처리 규칙을 명확히 정의해야 합니다.

정적·준정적 문제에서 두께·하중 변경에 따른 응력·변위 예측부터 검증하는 것이 합리적입니다. 낙하·충돌 같은 Explicit 동적 Simulation은 시간 의존성, Contact 상태 변화, 큰 변형, 소성 이력 등이 추가되므로 정적 실습의 10개 케이스

방식을 그대로 적용해서는 안 됩니다.

업무 활용 후보: 반복 설계조건 평가, 구조 대리모델, 고객 대상 실시간 결과 시각화, CAE 데이터의 AI 학습 자산화, API 기반 사내 예측 도구 구성.

16. 교육의 핵심 결론

- AI 모델을 선택하기 전에 신뢰할 수 있는 CAE 학습 데이터를 확보해야 합니다.
- DOE/LHS로 설계공간을 구성하되 케이스 수와 분포를 함께 검토해야 합니다.
- RST→VTU 변환은 확장자 변경이 아니라 Mesh·물리량·단위·정답 정합성 관리입니다.
- 응력 평균 순서, 변위 표현, 정규화, 샘플링 방식이 예측 정확도에 영향을 줍니다.
- 데이터 누출 방지와 독립된 Test 평가가 필요합니다.
- GNN·FNO·Transformer의 우열은 문제와 데이터에 따라 달라집니다.
- 학습된 모델을 API·Omniverse에 연결하면 조건 변경형 예측 인터페이스를 구축할 수 있습니다.
- 교육의 가장 큰 실무적 가치는 CAE 결과를 AI 학습 가능한 데이터 파이프라인으로 만드는 과정입니다.

17. 녹취 근거 및 불확실한 부분

이 문서는 2026-11-09 PhysicsNeMo 교육 1부·2부의 문맥 기반 오인식 보정본을 바탕으로 정리했습니다. 원본 음성과 직접 대조한 완전 교정본은 아닙니다. 시연 형상명, 오차율의 계산 기준, 일부 실습 명령어와 파일명, 학습시간·최종 오차, Transformer 모델 버전은 원본 강의자료로 재확인이 필요합니다.

수치의 성격: 두께 6~12 mm, 하중 100~500 N, 10개 설계점, 6/2/2 분할, 4,096 노드 샘플링, 2케이스 배치는 교육 예제값입니다. Simulation 정확도나 AI 모델 성능을 보장하는 공식 허용기준이 아닙니다.