PhysicsNeMo 교육 통합 상세 정리

오전·오후 녹취 보정 PDF 2종 통합 | 2026.11.10 | Simulation AI 모델 학습부터 Omniverse 시각화까지

문서 성격 원문 녹취 보정본 두 개를 근거로 교육의 핵심 내용과 실습 흐름을 통합한 상세 학습 노트입니다. 축어록은 아니며, 두 PDF에서 확인되는 기술적 사항을 가능한 한 빠짐없이 반영했습니다. 수치·명칭의 불확실성은 본문과 마지막 검증 목록에 표시했습니다.

1. 전체 교육 목적과 시스템 구성

교육 목표는 CAE/Simulation 결과를 AI 학습 데이터로 구성하고, NVIDIA PhysicsNeMo의 Transolver 모델을 학습·검증·시험한 후, 학습된 모델을 API 서비스로 배포하여 NVIDIA Omniverse에서 두께와 하중 조건을 바꾸면서 응력·변위 결과를 시각화하는 전체 워크플로를 구현하는 것입니다.

- 전체 흐름: DOE 및 Simulation 케이스 생성 → 데이터 변환·정규화 → Train/Validation/Test 분리 → Transolver 학습 및 체크포인트 저장 → 미학습 케이스 시험 → FastAPI/Uvicorn 추론 서버 → Mesh Morphing·표면 데이터 처리 → Omniverse Kit UI 연동 → 결과 저장·비교.
- 별도 CFD 사례를 통해 학습 케이스 수·DOE 분포·AI 아키텍처에 따른 예측 성능을 비교하고, 마지막에는 NVIDIA Holoscan과 센서 데이터를 연계한 디지털 트윈 확장 방향을 제시했습니다.

2. 실습 환경, 파일 구조, 실행 순서

2.1 실습 파일·가상환경 준비 [오전 02:23~25:11]

- 전날 사용한 교육 자료와 프로그램을 지정 작업 폴더로 옮기되, 파일을 개별 이동하지 않고 폴더 구조를 보존합니다. 실습 중 X: 드라이브의 개인 교육 폴더가 사용된 것으로 설명되며, 휘발성 저장소 여부와 실제 작업 경로를 확인해야 합니다.
- 압축 파일을 압축 프로그램 내부에서 직접 실행하지 말고 Bandizip의 '여기에 풀기' 등으로 완전히 해제합니다. 압축 해제 미완료는 실행 파일·환경 경로 미인식의 원인이 됩니다.
- Python 환경 관리 프로그램에서 Omniverse/PhysicsNeMo용 가상환경을 선택하고 Working Directory를 교육 폴더로 지정합니다. Jupyter Notebook을 실행한 후 올바른 Kernel인지 확인합니다. 환경 검색 실패 시 경로 등록, 압축 해제 상태, Kernel 연결을 점검합니다.
- 프로젝트별 가상환경과 패키지 버전을 관리하고 requirements.txt 등 의존성 목록을 남깁니다. 가상환경 디렉터리만 복사하면 절대경로 종속성 때문에 다른 PC에서 작동하지 않을 수 있습니다.

2.2 Notebook 실행 및 장 간 정보 전달 [오전 28:52~35:49, 오후 02:04~04:59]

- Notebook은 앞선 셀의 변수·객체를 다음 셀에서 사용하므로 순서대로 실행해야 합니다. 일부 셀을 건너뛰면 설정값, 경로, 체크포인트 및 실행 파일 생성이 누락될 수 있습니다.
- 학습 모델 체크포인트, 데이터 분할, 정규화 통계, 설정값과 후속 장에 필요한 연결 정보는 파일로 저장하여 다음 장에서 다시 불러옵니다. 교육에서는 JSON 설정 파일을 장 간 전달에 사용했습니다.
- 실습 중 실제로 일부 JSON 전달, 실행 경로 또는 Kit 인식이 누락되어 Omniverse 구동 오류가 발생했습니다. 코드를 모두 실행한다는 전제가 있었으므로, 실무에서는 각 단계의 필수 산출물 존재 여부를 사전 점검하는 편이 안전합니다.

3. DOE, 데이터 구성과 정규화

3.1 입력·출력 변수 및 데이터 분할 [오전 14:30~19:30, 25:39~35:49]

- DOE(Design of Experiments)로 설계 변수 범위와 Simulation 조건을 정의합니다. 구조 예제의 입력은 노드 좌표 X/Y/Z, 두께, 하중이며 출력은 노드별 응력(von Mises)과 변위 성분입니다. 응력과 변위는 공간장(Field)이므로 전체 분포를 예측합니다.
- 교육 학습 데이터는 6개 케이스, 검증 데이터는 2개 케이스로 설명됩니다. 오후 교육에서 별도 테스트 2개 케이스(Case 08, Case 03)를 평가합니다. 전체 데이터 분할과 케이스 ID 중복 여부는 실습 파일로 최종 확인해야 합니다.
- 학습(Training)은 역전파로 가중치를 갱신하고, 검증(Validation)은 모델 선택·하이퍼파라미터 판단에 사용하며, 최종 시험(Test)은 학습에 참여하지 않은 데이터의 일반화 성능을 확인합니다. 검증과 시험에서는 가중치를 갱신하지 않습니다.
- Z-score 표준화는 학습 데이터에서 산출한 평균 μ와 표준편차 σ를 기준으로 z=(x μ)/σ를 적용합니다. 검증·시험·서버 추론에도 동일한 μ, σ를 사용해야 데이터 누출과 스케일 불일치를 피할 수 있습니다.
- 모델 출력이 표준화된 값이라면 역정규화 x=zσ+μ를 수행한 뒤 MPa, mm 등 실제 물리 단위로 비교합니다. 역정규화 누락이나 입력·출력 스케일 혼동은 큰 오류를 유발합니다.

3.2 데이터 품질 및 분포

- 입력 공간의 중간뿐 아니라 경계와 급격한 물리 현상이 발생하는 구간까지 DOE가 대표하도록 구성합니다. 케이스 수가 많아도 특정 영역이 비어 있으면 그 영역의 일반화 성능은 낮을 수 있습니다.
- 이상치(outlier)는 학습을 왜곡할 수 있지만 실제 물리적 극값일 수도 있습니다. 측정 오류·Simulation 수치 불안정·실제 현상인지 확인한 후 제거 여부를 결정합니다. 이상치 필터링을 무조건 적용하는 것은 적절하지 않습니다.

4. Transolver 학습과 Epoch/Batch/Step

4.1 모델 학습 방식 [오전 36:06~43:25]

- Transolver는 공간장 예측 후보 모델로 사용되었습니다. 입력 좌표와 조건으로 응력·변위를 예측하며, Forward Pass → Loss 계산 → Backpropagation → Optimizer 업데이트를 반복합니다. 모든 구조·유동 문제에 항상 최적이라는 의미는 아닙니다.
- Step: 배치 1개를 처리하고 가중치를 업데이트하는 단위. Epoch: 학습 데이터 전체를 한 번 처리하는 단위. 학습 6케이스, 배치 2케이스, 중복 없는 분할을 가정하면 1 Epoch=3 Steps, 100 Epoch=300 Steps, 1,000 Epoch=3,000 Steps입니다.
- 본 학습 전에 소규모 배치로 Forward/Backward가 정상 작동하는지 확인합니다. 검증 Loss가 가장 좋은 시점의 가중치를 Checkpoint로 저장하고 시험·추론 단계에서 재사용합니다. best_model.pt는 설명용 파일명이며 실제 이름은 코드 확인이 필요합니다.

4.2 100 Epoch와 1,000 Epoch 비교 [오전 39:52~1:02:38]

- 초기 학습에서 Loss 감소를 관찰합니다. 녹취 보정본에는 학습 Loss 약 1.91→0.51, 검증 Loss 약 0.51→0.37, 응력 MAE 약 8~9 MPa가 언급되나, 원본 그래프·산식 없이 확정하기 어려운 참고값입니다.
- 100 Epoch에서는 전체 응력 분포 경향은 유사하지만 국부 응력 크기와 최대값 위치 오차가 남았습니다. 1,000 Epoch 학습 후 CAE 정답·AI 예측·절대오차 지도를 비교하여 개선을 확인했습니다.
- 교육 중 응력 오차가 약 8.6→1.5 수준으로 줄고, 실제 최대 응력 약 80에 대해 예측 약 79가 나왔다는 설명이 있습니다. 초기 최대 응력 위치 차이는 약 15 mm로 언급됩니다. 각각의 지표 정의·단위·케이스는 확인이 필요합니다.
- 변위는 X/Y/Z 성분별로 비교하며 초기부터 경향을 비교적 잘 따라간 것으로 설명됩니다. 변위의 전체 분포가 잘 맞더라도 응력 집중 위치가 틀릴 수 있으므로 결과별로 따로 평가해야 합니다.

- Epoch 증가가 언제나 정확도 향상을 뜻하지는 않습니다. 검증 성능, 과적합, 체크포인트 선택을 함께 검토합니다. Loss=0.93을 93% 오차로 해석할 수 없습니다. 손실함수 정의와 정규화 방식이 먼저 확인되어야 합니다.

5. 노드 샘플링, 전체 노드 학습과 GPU

[오전 1:02:38~1:17:11, 오후 24:47~27:38]

- 기본 실습은 케이스별 약 4,096개 노드 샘플링으로 학습했습니다. 비교 실습에서는 한 Step에 한 케이스를 넣고 해당 케이스의 전체 노드를 사용했습니다. 샘플링/전체 노드 방식에 따라 메모리·학습 시간·정확도가 달라질 수 있습니다.
- 작업 관리자 등에서 GPU 사용률과 전용 메모리를 확인합니다. 강의에서는 GPU 메모리 약 24 GB, 일부 샘플 배치 사용량 약 1~1.2 GB가 언급되지만 장비 사양과 측정 조건은 미확인입니다.
- 노드 수·Batch 크기·모델 구조에 따라 메모리 요구량이 변합니다. 단순한 정비례 관계로 일반화할 수 없으며 메모리 부족 시 샘플링, Batch 조절 및 메모리 절감 기법을 검토합니다.
- 전체 노드 학습이 무조건 더 정확하거나 반드시 과적합을 일으키는 것은 아닙니다. 동일한 미학습 케이스를 대상으로 MAE/RMSE·최대값·위치·분포를 비교해야 합니다. 일부 비교 셀은 경로·체크포인트 문제로 실행에 어려움이 있었습니다.

6. 테스트 케이스 평가와 오차 지표

6.1 독립 시험 절차 [오후 00:22~16:57]

- 학습 완료된 모델, 정규화 기준, 테스트 Case 08·03의 형상·두께·하중·CAE 정답 응력/변위를 로드합니다. 학습되지 않은 조건을 추론한 뒤 역정규화하여 실제 단위로 변환합니다.
- von Mises 응력은 정의상 0 이상입니다. AI 예측이 음수라면 물리적으로 부적절한 출력으로서 정규화 복원, 모델 출력 제약, 데이터 오류 등을 확인합니다.
- 원본과 예측의 컬러맵이 유사하더라도 국부 응력 구배가 큰 부위의 오차가 숨겨질 수 있습니다. 정답 분포, 예측 분포, 노드별 절대오차 지도, 최대값, 최대값 좌표를 함께 봅니다.
- MAE = (1/N)Σ| y |이며 평균적인 절대오차를 나타냅니다. RMSE = √[(1/N)Σ(y)²]는 큰 오차에 상대적으로 민감합니다. RMSE가 언제나 MAE보다 우수한 지표라는 뜻은 아닙니다.
- 학습 계산에는 float32, 평가 오차 집계에는 float64를 쓰는 방식을 소개합니다. float64로 변환해도 float32에서 이미 잃은 정밀도가 복원되지는 않지만, 합산 및 미세 차이 집계의 추가 반올림 오차를 줄일 수 있습니다.

6.2 Case 08 및 Case 03 정량 비교 [오후 17:31~24:33]

항목	Case 08	Case 03
원본 최대 von Mises 응력	약 63 MPa대	약 70 MPa
AI 예측 최대 응력	약 63 MPa대	약 74 MPa
원본/예측 최대 변위	약 0.33 / 0.35 mm	약 0.39 / 0.49 mm
최대 응력 위치	위치 차이 약 4.312 (단위 확인)	Case 08보다 차이 큼
종합 평가	분포·최대값 비교적 양호	응력·변위 오차 상대적으로 큼

※ 위 수치는 녹취 보정 PDF에 기재된 청취 기반 추정치입니다. Case 08 최대 응력 위치 차이의 단위, 축별 좌표 차이, 원본 결과표를 반드시 대조해야 합니다.

- Case 03에서 오차가 크면 해당 조건 영역에 새로운 Simulation 케이스를 추가하는 능동적 샘플링(Active Learning)을 고려합니다. 다만 최종 테스트 데이터 자체를 반복적인 모델 튜닝에 사용하면 독립 평가의 의미가 약해집니다.
- Case별 응력·변위의 절대 크기가 비슷하면 절대오차를 직접 비교하기 쉽지만, 물리량 규모가 크게 다르면 상대오차·정규화 오차도 병행해야 합니다. 상대오차는 정답이 0에 가까울 때 불안정합니다.
- 예측 배열과 메타데이터를 저장·재로딩하여 같은 입력의 추론 결과가 일치하는지 검증합니다. 교육에서는 재실행 시 최대 차이가 0으로 표시된 사례가 소개되었습니다.

7. CFD 사례와 모델 선택

7.1 DOE 40→100케이스 확대 [오전 1:17:23~1:29:31]

- 별도 CFD 예제는 형상을 고정하고 유속(또는 Reynolds 수)과 받음각을 변경해 속도장·압력장을 예측합니다. 초기 약 40케이스에서는 중간 조건이 비교적 양호하지만 저속·고속 경계 영역에서 오차가 컸습니다.
- Latin Hypercube Sampling(LHS)을 활용한 것으로 설명되며, 기존 40케이스를 유지하고 약 60케이스를 추가하여 총 100케이스로 학습했습니다. 이후 전체적인 예측 분포와 오차 지표가 개선된 것으로 설명됩니다.
- 오차 약 3~4% 수준이라는 발언이 있으나, 분모·산식·평가 케이스·변수는 확인되지 않았습니다. 입력 유속이 10→40 m/s처럼 크게 변하면 절대오차만으로 조건별 성능을 비교하기 어렵습니다.
- 유동 분리·재부착처럼 공간 분포가 급변하는 조건은 예측 난도가 높습니다. 단순한 데이터 양보다 DOE의 대표성, 고오차 영역 보강, 원본 CFD 품질이 중요합니다.

7.2 DoMINO, PINN, Transolver 비교 [오후 27:55~35:02]

- 강사는 워터펌프 등 유동 예제와 NVIDIA Blueprint 기반 구현 사례를 소개했습니다. 해당 CFD 비교에서는 DoMINO가 상대적으로 오차가 작고, PINN 계열 및 Transolver는 상대적으로 큰 오차를 보인 것으로 설명합니다. 이는 특정 데이터·설정의 결과이며 일반적인 모델 순위가 아닙니다.
- 웹 시각화 데모 중 일부는 추론 서버를 호출하지 않고 설계 공간의 결과를 미리 계산·저장한 뒤 화면에서 즉시 조회했습니다. 사전 계산 결과 조회는 실제 온라인 모델 추론보다 빠르지만 임의 조건의 즉시 추론과 다릅니다.
- NVIDIA가 제공하는 Blueprint·예제·워크플로는 개발 출발점으로 활용할 수 있지만, 자신의 Simulation 데이터 형식·물리 조건·오차 요구사항에 맞춰 재검증해야 합니다.

8. 추론 서버 구성: FastAPI + Uvicorn

8.1 전체 통신 구조 [오후 53:41~1:01:48]

Omniverse UI(두께·하중 입력) → HTTP API 요청 → FastAPI/Uvicorn 서버 → 입력 검증·정규화 → 학습 모델 추론 → 출력 역정규화 → JSON/배열 응답 → Omniverse 응력·변위 시각화

- 녹취의 '테스트 API'는 FastAPI, '유미콘'은 Uvicorn으로 보정됩니다. Uvicorn은 ASGI 서버이며 FastAPI 앱을 실행하고 HTTP 요청을 처리합니다. NVIDIA NIM 추론 마이크로서비스도 소개되지만 실습은 자체 API 서버를 사용했습니다. NIM의 비용·라이선스는 배포 조건에 따라 확인해야 합니다.
- 서버는 최적 모델 체크포인트와 정규화 기준을 로드한 후 요청을 기다립니다. 모델 추론을 CPU에서 수행할지 GPU에서 수행할지는 배치 설정에 따르며, 녹취만으로 실행 장치를 확정할 수 없습니다.
- 이 예제는 속도 최적화보다는 학습 모델과 UI 연결 구조를 익히는 데 초점을 둡니다. 상용 수준에서는 서버의 처리량, 지연시간, 동시 요청, 인증, 장애 복구를 별도로 설계해야 합니다.

8.2 요청·응답과 입력 범위 [오후 1:07:50~1:09:54]

- 클라이언트가 전달하는 주요 입력은 두께 6~12 mm와 하중 100~500입니다. 하중 단위는 N으로 추정되나 코드·교재 확인이 필요합니다. 기준 Case 01의 하중은 약 343.561로 들립니다.
- 요청 정보를 JSON으로 직렬화하여 API로 전송합니다. 서버는 허용 범위와 데이터 타입을 확인하고 범위 밖 입력은 명시적인 오류 응답으로 거부하도록 구성했습니다.
- 서버는 모핑된 형상 좌표와 입력 조건을 구성해 모델 추론을 수행하고, 필요한 노드의 응력·변위 배열을 반환합니다. 모델 버전·정규화 통계·노드 순서의 일관성이 중요합니다.

8.3 서버 실행과 기능 검증 [오후 1:09:54~1:24:28]

- Windows BAT 파일에 가상환경 활성화, 작업 디렉터리 이동, Uvicorn 실행 명령을 넣어 서버를 시작합니다. 콘솔의 실행 로그와 HTTP 주소를 확인하고, 서버가 제공하는 상태 확인용 페이지/엔드포인트로 정상 동작을 점검합니다.
- 서버 콘솔을 종료하면 해당 프로세스가 종료되므로 Omniverse 연동 중에는 유지해야 합니다. 외부 접속용으로 포트를 열 경우 방화벽·접근 통제·보안 정책을 검토해야 합니다.
- JSON 요청을 POST로 보내고 응답·서버 로그를 확인합니다. 로컬 직접 추론 결과와 API 경유 추론 결과의 최대 차이 0을 확인하여 동일 모델·전처리·후처리가 적용되는지 검증했습니다.
- 두께 6 mm 및 12 mm 조건을 비교하여 모핑과 결과 변화가 합리적인지 확인했습니다. 이 예제에서는 얇은 경우 응력이 높았으나 모든 구조·하중 조건에 대한 보편 법칙으로 일반화해서는 안 됩니다.
- 두께 99 등 설계 범위를 벗어난 입력은 오류로 처리합니다. AI 대리모델은 외삽(Extrapolation)에 취약할 수 있으며, 학습 범위 안에서도 경계 영역의 오차가 클 수 있습니다.

9. Mesh Morphing, PyVista, STL 및 결과 전달

[오후 1:02:20~1:07:14, 1:18:13~1:20:20]

- 두께를 변경할 때 매번 CAD 수정·Mesh 재생성을 하지 않고 기존 Mesh 노드의 두께 방향 좌표를 비율에 따라 이동시키는 Mesh Morphing을 사용합니다. 교육 예제에서는 기준면을 유지하고 주로 Z 방향 좌표를 변화시키는 형태로 설명됩니다.
- 기준 Case 01 두께가 약 10.9 mm로 들리며, 두께 6 mm/12 mm에 대한 모핑 결과를 비교했습니다. 정확한 기준 두께와 좌표식은 교재·코드 확인이 필요합니다.
- 단순한 두께 스케일 변화는 모핑으로 처리할 수 있으나 라운드, 위상 변경, 복잡한 형상 변화는 CAD 및 Mesh 재생성이 필요할 수 있습니다. 모핑 시 요소 왜곡·음의 Jacobian 등 품질 문제를 점검해야 합니다.
- 전체 노드에서 AI 추론을 수행하더라도 Omniverse가 외부 표면만 보여주면 표면 Mesh와 필드만 전송하여 데이터량을 줄일 수 있습니다. 단면·내부 필드를 표시하려면 관련 내부 노드와 데이터가 필요합니다.
- PyVista를 사용하여 표면을 추출하고 STL을 생성합니다. STL은 일반적으로 표면 삼각형의 기하 정보를 담으며 노드 ID·연결성·응력·변위와의 대응 관계는 별도 파일/배열로 관리해야 합니다. 결과 시각화와 비교 이미지도 PyVista로 생성할 수 있습니다.

10. NVIDIA Omniverse Kit 연동 실습

10.1 실행과 UI [오후 1:25:00~1:42:21]

- 추론 서버를 실행한 상태에서 Omniverse Kit용 실행 파일을 구동합니다. 강의에서는 OpenUSD/Omniverse의 복잡한 조작을 줄이기 위해 미리 구성한 교육용 UI를 사용했습니다.

- UI에는 두께·하중 슬라이더, Auto Update, 표시 필드 선택(AI Stress/Displacement), Reference 목록, Apply, Save Result가 있습니다. 슬라이더 변경 시 서버에 요청을 보내고 결과 필드를 갱신합니다.
- Auto Update를 끄면 자동 추론 요청을 멈추고 다시 켜면 결과 갱신을 재개합니다. 카메라 확대·축소·회전은 일반 CAD 도구와 조작감이 달라 익숙해지는 시간이 필요하다고 설명합니다.
- 실습 중 일부 교육생은 Kit 경로 인식, 이전 장의 JSON 전달 또는 셀 실행 누락으로 UI 실행 오류를 겪었습니다. 강사는 필수 코드 순차 실행을 전제로 작성한 교육 자료의 한계를 설명했습니다.

10.2 기준 조건, 결과 저장과 비교 [오후 1:37:24~1:45:40]

- Case 01 기준 조건을 불러오고 하중 약 343.561(단위 확인 필요)을 사용했습니다. Reference에서 미리 준비한 얇은/두꺼운/하중 변경 조건을 선택하고 Apply로 적용합니다.
- 화면 오른쪽 아래 Save Result를 눌러 현재 추론 결과를 파일로 저장합니다. 교육에서는 4개 사전 설정 조건을 각각 저장하고 Notebook에서 다시 불러 비교하도록 안내했습니다.
- 실시간 모델 추론에는 연산·네트워크·렌더링 지연이 존재합니다. 조건별 결과를 미리 생성해 캐시에서 읽으면 화면 반응이 빨라지지만 온라인 추론과는 다릅니다.
- 저장 후 분석 셀은 저장된 응력·변위 결과를 읽고 비교하는 용도입니다. UI에서 어떤 물리량을 저장했는지, 결과 폴더가 실제 생성되었는지, 모델 ID와 파일이 일치하는지 확인해야 합니다. 강의 중 일부 실습은 실행 오류로 생략되었습니다.

11. 디지털 트윈과 센서 연계 확장

[오후 1:45:40~1:50:01]

- 향후 구상은 시험 장비·현장 센서에서 데이터를 수집하여 NVIDIA Holoscan으로 스트리밍 신호 처리하고, AI 추론 서버를 거쳐 Omniverse에서 장비 상태를 시각화하는 디지털 트윈입니다.
- 센서 데이터는 노이즈, 이상 신호, 누락 등이 발생하므로 필터링·전처리·특징 추출이 필요합니다. Holoscan은 GPU 가속 스트리밍 처리에 활용할 수 있으나 모든 처리의 실시간성을 자동 보장하는 것은 아닙니다.
- 구상한 활용 분야는 장비 상태 모니터링, 이상 징후 탐지 및 예지보전입니다. 실제 구축에는 계측 대상 선정, 센서 신뢰성, 데이터 동기화, 모델 일반화 성능, 전체 파이프라인 지연시간 및 운영 인프라 검증이 필요합니다.

12. 실무 적용을 위한 검증 체크리스트

- 환경: Python·CUDA·PyTorch·PhysicsNeMo·Omniverse Kit 버전 및 가상환경 재현 가능성, 실행 경로와 의존성 파일 확인
- 데이터: 입력/출력 필드의 단위, 노드 ID/순서, 학습·검증·시험 분리, 정규화 통계 재사용, 데이터 누출 여부 확인
- 학습: Batch·Step·Epoch 정의, 체크포인트 선택 근거, 학습/검증 Loss 추이, 전체 노드/샘플링 조건 비교
- 정확도: MAE/RMSE의 단위와 산식, 최대 응력·변위·위치 오차, 공간장 오차, 경계·고구배 영역의 신뢰성 평가
- 서버: 직접 추론과 API 추론 일치, 허용 입력 범위, 범위 외 요청 오류 처리, 모델·정규화·노드 매핑 버전 관리
- 시각화: 모핑 후 Mesh 품질, STL 표면과 필드 매핑, Omniverse 저장 결과 파일 경로·생성 여부·재현성 확인
- 운영: CPU/GPU 장치 선택, GPU 메모리, API 보안, 지연시간·동시 요청, 서버 상시 실행과 장애 복구 검토

13. 원문과 대조가 필요한 수치·명칭

- 교육 실습 환경의 정확한 Python 환경 관리 프로그램명, X: 드라이브 경로, Omniverse Kit 실행 파일 및 폴더명
- 학습 6/검증 2/시험 2 케이스의 정확한 ID 분할과 전체 케이스 구성

- 학습 Loss 1.91→0.51, 검증 Loss 0.51→0.37, MAE 8~9 MPa, 오차 8.6→1.5, 최대 응력 80/79, 위치 오차 15 mm의 실제 정의·단위·케이스
- Case 08: 최대 응력 약 63 MPa대, 최대 변위 0.33/0.35 mm, 위치 차이 4.312의 단위와 축별 좌표
- Case 03: 최대 응력 70/74 MPa, 최대 변위 0.39/0.49 mm 및 위치 차이
- Case 01 기준 두께 약 10.9 mm, 하중 약 343.561, API 하중 범위 100~500의 단위
- GPU 약 24 GB와 학습 메모리 약 1~1.2 GB, CFD 40→100케이스 및 3~4% 오차의 원본 자료
- Omniverse 특정 구성요소 명칭, NVIDIA Blueprint, NIM 서비스 조건, Holoscan 버전과 적용 예시

최종 요지: 이 교육은 단순한 AI 학습 예제가 아니라, Simulation 데이터 기반 대리모델을 만들고 이를 API로 서비스화하여 Omniverse UI에서 조건 변경·추론·저장까지 연결하는 End-to-End 실습입니다. 실제 적용에서 핵심은 Epoch 수보다 데이터의 품질·분포, 독립 시험 정확도, 정규화/노드 매핑 일관성, 입력 범위 통제 및 재현성입니다.

출처: 「PhysicsNeMo AI 학습 및 가상환경 설정 교육 녹취 보정본」(4쪽), 「PhysicsNeMo 교육 녹취록 보정본 | 모델 평가·추론 서버·Omniverse」(4쪽). 두 자료는 원본 음성 대조 없이 작성된 보정·재구성본이므로 수치와 제품명에 한계가 있습니다.